基于强化学习的交通信号控制：方案设计

2026 年 10 月 20 日

1 项目目标

本项目以单路口信号控制为对象，训练智能体依据实时交通状态自适应地选择信号相位，并与固定时长、基于队列两类经典控制器进行可复现的对比，分析学习型控制相对规则型控制的收益及其来源。

2 环境选择

采用 SUMO 结合 SUMO-RL 构建仿真环境。SUMO 原生支持车辆跟驰、排队形成与信号控制，可避免自建排队模型时对服务率等作出过度简化；SUMO-RL 将仿真封装为 Gymnasium 环境并提供单路口路网，使环境、智能体与基线解耦实现、共享同一套评价代码。该方案更接近真实交通，代价是环境配置成本较高、仿真较慢，训练时可关闭图形界面并以 libsumo 加速。

路口设为单十字路口，四个进口方向各设左转、直行、右转三条车道；信号采用四相位方案（南北直行、南北左转、东西直行、东西左转），其中左转为保护式左转，即对向直行显示红灯。该设置可刻画左转与对向直行的冲突，较两相位更真实，但会增大状态与动作空间，对表格法构成挑战，此权衡亦作为分析内容。车辆按各方向独立的泊松过程到达，转向比例由路由文件给定，每个回合仿真一小时。智能体按固定间隔决策，切换相位时插入黄灯过渡；动作为选择下一个绿灯相位，观测包括当前相位、最小绿灯标志以及各车道的车辆数与排队长度。

3 算法与模型设计

将控制问题形式化为马尔可夫决策过程：状态由观测离散化得到，包含当前相位、最小绿灯标志与各车道排队长度及车辆数的分箱；动作为选择下一个绿灯相位；奖励主用相邻决策间全局累计等待时间的减少量，并与队列惩罚（各车道排队数之和的负值）作对比；折扣因子取 0.95。前者直接对应优化目标，后者更强调抑制长队列，两者对比可反映奖励设计对所学策略的影响。

表格型 Q-learning 以 ε-greedy 策略探索，按下式更新动作价值，ε 由 1.0 逐步衰减至 0.05：

$$Q(s,a) \leftarrow Q(s,a) + \alpha\Big[\, r + \gamma \max_{a'} Q(s',a') - Q(s,a) \Big] \tag{1}$$

表格法无须神经网络、可解释且稳定，但需人工离散化，四相位三车道下状态空间较大、收敛较慢。为此进一步实现 DQN：以连续观测为输入，用神经网络逼近动作价值，并配合经验回放与目标网络，以规避手工离散化与状态爆炸。路线分两阶段：先完成表格法获得可解释结果，再以 DQN 对照，比较性能、收敛速度与泛化能力。

4 Baseline

- **固定时长控制:**按固定周期与绿信比循环切换相位，不感知实时交通状态，代表“无自适应”的下界
- **基于队列控制:**在每个决策点统计各相位对应车道的排队总和，优先放行排队更长的相位并服从最小绿灯约束，代表“无学习的自适应”控制

5 评估

评估按由易到难的次序组织为四个阶梯，先在第一级跑通完整流程并确认指标合理，再逐级加压，且每次只改变一个变量以便归因。

表 1 评估场景设置

阶梯	交通条件	总需求（veh/h）	方向比
S1	低流量、方向均衡	600	1:1:1:1
S2	中流量、方向均衡	1200	1:1:1:1
S3	高流量、方向均衡	2000	1:1:1:1
S4	中流量、方向不均衡	1200	3:1:1:1

- **主指标：**平均等待时间、平均队列长度
- **其他指标：**最大队列长度、吞吐量、平均延误、相位切换次数

主指标为平均等待时间与平均队列长度，辅以最大队列长度、吞吐量、平均延误与相位切换次数；强化学习部分另报告学习曲线与收敛速度。训练与测试分离，每个“控制器—场景”组合使用多个随机种子并报告均值与标准差。据此分析：强化学习是否优于两类基线及其优势场景、四相位下能否学到合理策略、表格法与 DQN 的差异，以及奖励设计对控制行为的影响。